TRƯỜNG ĐẠI HỌC CÔNG NGHỆ – ĐHQG HÀ NỘI

Ngữ nghĩa và biểu diễn từ Xử lý ngôn ngữ tự nhiên

Giảng viên: TS. Vương Thị Hải Yến
yenvth@vnu.edu.vn

Nội dung buổi học

- **Nghĩa từ vựng**
- **Giả thuyết phân bố**
- **Word embedding**

Nghĩa từ vựng

Nghĩa của từ, quan hệ nghĩa, WordNet và bài toán phân giải nghĩa

Từ, lemma và nghĩa của từ

- Một **lemma** là dạng gốc đại diện cho mọi cách dùng của một từ trong từ điển.
- Mỗi lemma có thể mang nhiều **nghĩa (sense)**; ví dụ, “crane” có thể chỉ con sếu hoặc cần cẩu.
- Việc xác định nghĩa đang được dùng là **tiền đề** cho dịch máy, truy hồi thông tin và hỏi đáp.

Đồng âm và đa nghĩa

- Nhập nhằng nghĩa từ vựng gồm hai loại là **đồng âm** và **đa nghĩa**.
- Phân giải từ **đa nghĩa** khó hơn, vì các nghĩa gần nhau và ranh giới giữa chúng không rõ ràng.

Loại	Đặc điểm	Ví dụ tiếng Anh	Ví dụ tiếng Việt
Đồng âm (homonym)	Cùng hình thức, các nghĩa không liên quan với nhau	mail: thư tín / áo giáp pole: cây sào / cực Trái Đất	đường: chất ngọt / lối đi bàn: đồ vật / bàn bạc
Đa nghĩa (polyseme)	Một nghĩa phát sinh từ nghĩa khác	branch: cành cây / chi nhánh wood: gỗ / khu rừng	chân: chân người / chân núi mũi: mũi người / mũi đất

Quan hệ nghĩa giữa các từ

- Các quan hệ nghĩa là cơ sở để tổ chức từ vựng trong những tài nguyên như **WordNet**.

Quan hệ	Định nghĩa	Ví dụ
Đồng nghĩa	Hai từ thay thế được cho nhau trong phần lớn ngữ cảnh	máy bay – phi cơ
Trái nghĩa	Hai từ đối lập trên cùng một chiều nghĩa	nóng – lạnh
Thượng danh – hạ danh	Một khái niệm bao hàm khái niệm kia	động vật – chó
Bộ phận – toàn thể	Một đối tượng là thành phần của đối tượng kia	bánh xe – ô tô

Tương đồng và liên quan về nghĩa

- Hai từ **tương đồng** khi chúng chia sẻ nhiều đặc điểm nghĩa, ví dụ “xe máy” và “ô tô”.
- Hai từ **liên quan** khi chúng thường xuất hiện trong cùng một tình huống, ví dụ “xe máy” và “xăng”.
- Các phương pháp biểu diễn từ dựa trên đồng xuất hiện thường không tách biệt được hai quan hệ này.

WordNet

- **WordNet** là cơ sở dữ liệu từ vựng tiếng Anh do Đại học Princeton xây dựng thủ công.
- Mỗi nghĩa được biểu diễn bằng một **synset**, tức tập các từ đồng nghĩa kèm một định nghĩa ngắn gọi là **gloss**.
- Các synset được nối với nhau bằng quan hệ nghĩa như thượng danh, hạ danh và bộ phận – toàn thể.

Danh từ “bank” có nhiều synset trong WordNet

- Trong WordNet 3.0, danh từ **bank** có **10 synset** và động từ bank có 8 synset; bảng dưới liệt kê ba nghĩa danh từ tiêu biểu.

Synset	Các từ trong synset	Định nghĩa (gloss)	Thượng danh trực tiếp
bank.n.01	bank	sloping land (especially the slope beside a body of water)	slope.n.01
bank.n.02	depository financial institution, bank, banking concern, banking company	a financial institution that accepts deposits and channels the money into lending activities	financial_institution.n.01
bank.n.09	bank, bank building	a building in which the business of banking transacted	depository.n.01

- Chuỗi **thượng danh** của bank.n.02 là financial_institution → institution → organization → social_group → group → abstraction → entity.

Hệ thống phân cấp danh từ trong WordNet

- Danh từ trong WordNet được tổ chức thành **cây thượng danh** có gốc là “entity”.
- Khái niệm cụ thể nằm ở tầng lá và khái niệm khái quát nằm gần gốc, ví dụ chuỗi “chó → động vật có vú → động vật → thực thể” (đã rút gọn).
- Khoảng cách trên cây được dùng để đo **độ tương đồng**, ví dụ bằng độ đo path hoặc Wu–Palmer.

WordNet tiếng Việt và hạn chế của tài nguyên thủ công

- Tiếng Việt đã có một số dự án xây dựng **WordNet tiếng Việt**, nhưng độ phủ còn thấp hơn nhiều so với WordNet tiếng Anh.
- Tài nguyên xây dựng thủ công đòi hỏi **chi phí lớn** và được cập nhật chậm so với sự thay đổi của ngôn ngữ.
- WordNet thiếu nhiều **từ mới, thuật ngữ chuyên ngành và tiếng lóng**, đồng thời không lượng hóa được mức độ tương đồng giữa các từ.

Bài toán phân giải nghĩa của từ

- **Phân giải nghĩa của từ (WSD)** là bài toán xác định nghĩa của một từ nhập nhằng trong một ngữ cảnh cụ thể.
- Trong câu "They hoisted cargo with a **crane**", từ "crane" mang nghĩa cần cẩu chứ không phải con sếu.
- WSD là một dạng **phân tích ngữ nghĩa**, với đầu ra là một nghĩa trong kho nghĩa đã định trước.

Hai hướng tiếp cận WSD

- Các phương pháp WSD khác nhau ở **nguồn tri thức** được dùng để phân biệt các nghĩa.

Hướng tiếp cận	Nguồn tri thức	Phương pháp tiêu biểu
Dựa trên từ điển	Định nghĩa các nghĩa trong từ điển và từ điển đồng nghĩa	Mô hình Lesk và các mở rộng
Học máy	Ngữ liệu có hoặc không có nhãn nghĩa	Naive Bayes, danh sách quyết định, bootstrapping

Mô hình Lesk

- Mô hình Lesk chọn nghĩa có **nhiều từ trùng nhất** giữa định nghĩa từ điển của nghĩa đó và định nghĩa của các từ trong ngữ cảnh.
- Trong câu "The cigar burns slowly and creates a stiff ash", từ "burns" trong ngữ cảnh trùng với "burned" trong định nghĩa của nghĩa **tro**, nên "ash" được gán nghĩa tro.
- Mô hình chỉ đạt độ chính xác **50–70%** vì định nghĩa từ điển ngắn và nhiều trường hợp không có từ trùng.
- Các bản mở rộng xác định nghĩa của mọi từ trong câu cùng lúc, hoặc bổ sung **từ đồng nghĩa** để tăng số từ trùng.

Học có giám sát với Naive Bayes

- WSD có thể được xem là **bài toán phân loại**, trong đó mỗi nghĩa là một lớp và các từ trong ngữ cảnh là đặc trưng.
- Trong câu "They hoisted cargo with a crane", từ "cargo" cho biết "crane" mang nghĩa cần cẩu.
- Mô hình **Naive Bayes** kết hợp tần suất của mỗi nghĩa với mức độ đồng xuất hiện giữa nghĩa đó và các từ ngữ cảnh, học từ ngữ liệu đã gán nhãn nghĩa.
- Thực nghiệm trên ngữ liệu song ngữ Anh – Pháp **Hansard** với sáu từ nhập nhằng đạt độ chính xác khoảng **90%**.

Danh sách quyết định của Yarowsky

- Danh sách quyết định là tập **luật IF-THEN** được xếp hạng theo độ tin cậy, và nghĩa được xác định bởi luật khớp có thứ hạng cao nhất.
- Khác với Naive Bayes dùng mọi đặc trưng, phương pháp này chỉ dùng **một đặc trưng đáng tin cậy nhất** cho mỗi quyết định.

Mẫu luật	**Ý nghĩa**
IF (w_{i-1} = x) THEN sense = y	Từ đứng trước là x
IF (w_{i+1} = x) THEN sense = y	Từ đứng sau là x
IF (x ∈ ±k từ) THEN sense = y	x xuất hiện trong cửa sổ ±k từ
IF (true) THEN sense = s_A	Luật mặc định chọn nghĩa phổ biến nhất

Học bán giám sát bằng bootstrapping

- **Bootstrapping** mở rộng dần dữ liệu huấn luyện từ một lượng nhỏ **dữ liệu mồi** và chỉ giữ lại các nhãn có độ tin cậy cao.
- Dữ liệu mồi được tạo từ một từ định nghĩa cho mỗi nghĩa, ví dụ “bird” và “machine” cho “crane”, từ định nghĩa từ điển, hoặc bằng gán nhãn thủ công.
- Giả định **một nghĩa cho mỗi văn bản** gán cùng một nghĩa cho mọi lần xuất hiện của từ trong cùng văn bản.

Bước	Nội dung
1	Tạo **dữ liệu mồi (seed)**, tức một lượng nhỏ dữ liệu có nhãn nghĩa
2	Học danh sách quyết định DL_i từ dữ liệu huấn luyện hiện có
3	Áp dụng DL_i cho dữ liệu chưa gán nhãn và bổ sung các mẫu có độ tin cậy vượt ngưỡng vào dữ liệu huấn luyện
4	Lặp lại bước 2 và bước 3 cho đến khi dữ liệu huấn luyện không thay đổi

Kết quả thực nghiệm của Yarowsky

Từ	Hai nghĩa	Số mẫu	Từ định nghĩa	Từ điển	Thủ công	OSPD cuối	OSPD mỗi vòng
plant	thực vật / nhà máy	7538	97,1%	97,3%	97,6%	98,3%	98,6%
space	thể tích / vũ trụ	5745	89,1%	92,3%	93,5%	93,3%	93,6%
tank	xe tăng / bể chứa	11420	94,2%	94,6%	95,8%	96,1%	96,5%
motion	kiến nghị / chuyển động	11968	93,5%	97,4%	97,4%	97,8%	97,9%
bass	cá vược / âm trầm	1859	96,6%	97,2%	97,7%	98,5%	98,8%
palm	cây cọ / bàn tay	1572	93,9%	94,7%	95,8%	95,5%	95,9%
poach	săn trộm / chần	585	96,6%	97,2%	97,7%	98,4%	98,5%
axes	trục tọa độ / rìu	1344	94,0%	94,3%	94,7%	96,8%	97,0%
duty	thuế / nghĩa vụ	1280	90,4%	92,1%	93,2%	93,9%	94,1%
drug	thuốc / ma túy	1380	90,4%	91,4%	92,6%	93,3%	93,9%
sake	lợi ích / rượu sake	407	59,6%	95,8%	96,1%	96,1%	97,5%
crane	con sếu / cần cẩu	2145	92,3%	93,6%	94,2%	95,4%	95,5%
Trung bình		3936	90,6%	94,8%	95,5%	96,1%	96,5%

Baseline chọn nghĩa phổ biến nhất đạt 63,9%. OSPD: một nghĩa cho mỗi văn bản.

Tổng kết các phương pháp WSD

- Các con số được đo trên những tập từ và ngữ liệu khác nhau, nên chỉ phản ánh **xu hướng** chứ không phải so sánh trực tiếp.

Phương pháp	Nguồn tri thức	Dữ liệu cần có	Độ chính xác
Lesk	Định nghĩa từ điển	Không cần ngữ liệu gán nhãn	50–70%
Naive Bayes	Đồng xuất hiện với từng nghĩa	Ngữ liệu gán nhãn nghĩa	≈ 90%
Danh sách quyết định và bootstrapping	Kết hợp từ có độ tin cậy cao	Dữ liệu mồi nhỏ và ngữ liệu thô	≈ 96%

Giả thuyết phân bố

Biểu diễn nghĩa của từ bằng thống kê đồng xuất hiện

Giả thuyết phân bố

- **Giả thuyết phân bố** cho rằng các từ xuất hiện trong ngữ cảnh tương tự thì có nghĩa tương tự (Harris, 1954).
- Firth (1957) diễn đạt ý tưởng này bằng câu "You shall know a word by the company it keeps".
- Nếu "phở" và "bún" cùng đi với "ăn", "bát" và "nóng", mô hình có thể suy ra hai từ này gần nghĩa mà không cần từ điển.

Đoán nghĩa từ “tezgüino” qua ngữ cảnh

- Ví dụ sau cho thấy con người cũng suy ra nghĩa của từ theo đúng **giả thuyết phân bố**.
- Người đọc chưa từng gặp từ **tezgüino** vẫn đoán được nghĩa của nó nhờ các ngữ cảnh dưới đây (Lin, 1998).

Câu ngữ cảnh	**Thông tin người đọc suy ra**
A bottle of tezgüino is on the table.	Tezgüino là chất lỏng đựng trong chai.
Everybody likes tezgüino.	Tezgüino là thứ được nhiều người ưa thích.
Tezgüino makes you drunk.	Tezgüino có chứa cồn.
We make tezgüino out of corn.	Tezgüino được làm từ ngô.

- Có thể kết luận **tezgüino là một loại đồ uống có cồn làm từ ngô**, tương tự bia.

Ma trận từ – văn bản và từ – ngữ cảnh

- **Ma trận từ – văn bản** ghi số lần mỗi từ xuất hiện trong mỗi văn bản và được dùng phổ biến trong truy hồi thông tin.
- **Ma trận từ – ngữ cảnh** ghi số lần hai từ cùng xuất hiện trong một cửa sổ, nhờ đó mỗi hàng trở thành vector của một từ.
- Ma trận có kích thước bằng bình phương kích thước từ vựng và phần lớn các ô có giá trị bằng 0.

Cửa sổ ngữ cảnh

- **Cửa sổ ngữ cảnh** hẹp (±1–3 từ) phản ánh quan hệ cú pháp, còn cửa sổ rộng phản ánh quan hệ chủ đề.
- Cửa sổ thường **đối xứng**, tức không phân biệt ngữ cảnh bên trái hay bên phải, và có độ dài phổ biến từ 5 đến 10 từ.
- Mỗi hàng của ma trận từ – ngữ cảnh là một vector đếm; độ tương đồng giữa các vector này được đo bằng **tích vô hướng** hoặc **cosine** ở hai slide tiếp theo.

Đo độ tương đồng bằng tích vô hướng

- Với hai vector từ v và w, cách đo độ tương đồng đơn giản nhất là **tích vô hướng**.

$$\text{dot}(v, w) = v \cdot w = \sum_{i=1}^{N} v_i w_i = v_1 w_1 + v_2 w_2 + \cdots + v_N w_N$$

- Tích vô hướng **lớn** khi hai vector có giá trị lớn ở cùng các chiều và **bằng 0** khi hai vector trực giao.
- Tích vô hướng tăng theo **độ dài vector**, mà từ có tần suất cao thường có vector dài hơn, nên phép đo bị **thiên lệch theo tần suất**.
- Chia tích vô hướng cho độ dài của hai vector sẽ loại bỏ ảnh hưởng này; kết quả là **độ tương đồng cosine**.

Cosine loại bỏ ảnh hưởng của độ dài vector

$$\cos(v, w) = \frac{v \cdot w}{|v||w|} = \frac{\sum_{i=1}^{N} v_i w_i}{\sqrt{\sum_{i=1}^{N} v_i^2}\sqrt{\sum_{i=1}^{N} w_i^2}}$$

- Cosine nằm trong khoảng **[−1, 1]**; với vector không âm như vector đếm, giá trị nằm trong **[0, 1]**.

Cặp từ	Cosine	Diễn giải
cat – dog	0,987	Cao vì cả hai đều là động vật.
car – bike	0,995	Cao vì cả hai đều là phương tiện giao thông.
cat – car	0,447	Thấp vì hai từ thuộc hai nhóm nghĩa khác nhau.

Hạn chế của tần suất thô

- Các **từ chức năng** như "của", "và", "là" xuất hiện cạnh hầu hết mọi từ nên chiếm ưu thế trong vector.
- Tần suất thô không phân biệt được đồng xuất hiện **có ý nghĩa** với đồng xuất hiện **ngẫu nhiên**.
- Do đó cần một trọng số phản ánh mức độ hai từ đi cùng nhau nhiều hơn kỳ vọng.

Word embedding

word2vec, GloVe và fastText

Biểu diễn nghĩa của một từ

- Theo từ điển Webster, **nghĩa** là ý tưởng được biểu thị bằng một từ hoặc cụm từ.
- Nghĩa cũng là ý tưởng mà một người muốn diễn đạt bằng từ ngữ hoặc ký hiệu.
- Nghĩa còn là ý tưởng được thể hiện trong một tác phẩm viết hoặc nghệ thuật.

- Cách hiểu phổ biến nhất về nghĩa trong ngôn ngữ học là **ngữ nghĩa sở chỉ (denotational semantics)**:

signifier (ký hiệu) ⟺ signified (ý niệm hoặc sự vật)

tree ⟺ {    , ... }

Ba cách biểu diễn từ trong NLP

- **Biểu diễn từ** là cách chuyển một từ thành dạng số để mô hình học máy xử lý được; có ba nhóm biểu diễn chính.

Loại biểu diễn	Cách biểu diễn	Ví dụ	Hạn chế chính
Ký hiệu	Mỗi từ là một ký hiệu rời rạc; quan hệ nghĩa lấy từ cơ sở tri thức	WordNet	Tốn công xây dựng, thiếu từ mới, khó đo độ tương đồng
Thưa	Vector nhiều chiều, hầu hết giá trị bằng 0	One-hot, ma trận đồng xuất hiện	Không thể hiện quan hệ nghĩa; số chiều tăng theo từ vựng
Dày	Vector ít chiều (50–300) với giá trị thực	word2vec, GloVe, fastText	Cần nhiều dữ liệu; mỗi từ chỉ có một vector

Biểu diễn từ như các ký hiệu rời rạc

- Trong NLP truyền thống, từ được coi là **ký hiệu rời rạc**, ví dụ hotel, conference, motel; đây là một **biểu diễn cục bộ** (localist representation).
- Các ký hiệu này được biểu diễn bằng **vector one-hot**, trong đó có một phần tử bằng 1 và các phần tử còn lại bằng 0.

$$\text{motel} = [0\ 0\ 0\ 0\ 0\ 0\ 0\ 0\ 0\ 0\ 1\ 0\ 0\ 0\ 0]$$
$$\text{hotel} = [0\ 0\ 0\ 0\ 0\ 0\ 0\ 1\ 0\ 0\ 0\ 0\ 0\ 0\ 0]$$

- Số chiều của vector bằng **số từ trong từ vựng**, ví dụ hơn 500.000.

Vấn đề của biểu diễn ký hiệu rời rạc

- Trong tìm kiếm web, khi người dùng tìm “Seattle motel”, hệ thống cần khớp cả các văn bản chứa “Seattle hotel”.

$$\text{motel} = [0\ 0\ 0\ 0\ 0\ 0\ 0\ 0\ 0\ 0\ 1\ 0\ 0\ 0\ 0]$$
$$\text{hotel} = [0\ 0\ 0\ 0\ 0\ 0\ 0\ 1\ 0\ 0\ 0\ 0\ 0\ 0\ 0]$$

- Hai vector này **trực giao**, nên vector one-hot **không có khái niệm tương đồng** tự nhiên.
- Có thể dựa vào danh sách đồng nghĩa của WordNet, nhưng cách này thất bại rõ rệt vì WordNet không đầy đủ.
- Giải pháp là **học cách mã hóa độ tương đồng** ngay trong bản thân các vector.

Nghĩa của từ được xác định qua ngữ cảnh

- **Ngữ nghĩa phân bố** là cơ sở của word vector: như phần Giả thuyết phân bố đã trình bày, nghĩa của một từ được xác định bởi các từ thường xuất hiện gần nó.
- **Ngữ cảnh** của từ w là tập các từ xuất hiện trong một cửa sổ kích thước cố định quanh w.
- Nhiều ngữ cảnh khác nhau của w được dùng để xây dựng **biểu diễn của w**; đây là một trong những ý tưởng thành công nhất của NLP thống kê hiện đại.

Các ngữ cảnh biểu diễn cho từ "banking"
…government debt problems turning into **banking** crises as happened in 2009…
…saying that Europe needs unified **banking** regulation to replace the hodgepodge…
…India has just given its **banking** system a shot in the arm…

Word vector là biểu diễn dày đặc và phân tán

- Mỗi từ được gán một **vector dày đặc**, được chọn sao cho gần với vector của các từ xuất hiện trong ngữ cảnh tương tự.
- Độ tương đồng giữa hai từ được đo bằng **tích vô hướng** của hai vector tương ứng.
- Word vector còn được gọi là **word embedding** hoặc biểu diễn từ bằng mạng nơ-ron; đây là một **biểu diễn phân tán** vì nghĩa được trải trên nhiều chiều.

$$\mathbf{banking} = \begin{bmatrix} 0{,}286 \\ 0{,}792 \\ -0{,}177 \\ -0{,}107 \\ 0{,}109 \\ -0{,}542 \\ 0{,}349 \\ 0{,}271 \end{bmatrix} \qquad \mathbf{monetary} = \begin{bmatrix} 0{,}413 \\ 0{,}582 \\ -0{,}007 \\ 0{,}247 \\ 0{,}216 \\ -0{,}718 \\ 0{,}147 \\ 0{,}051 \end{bmatrix}$$

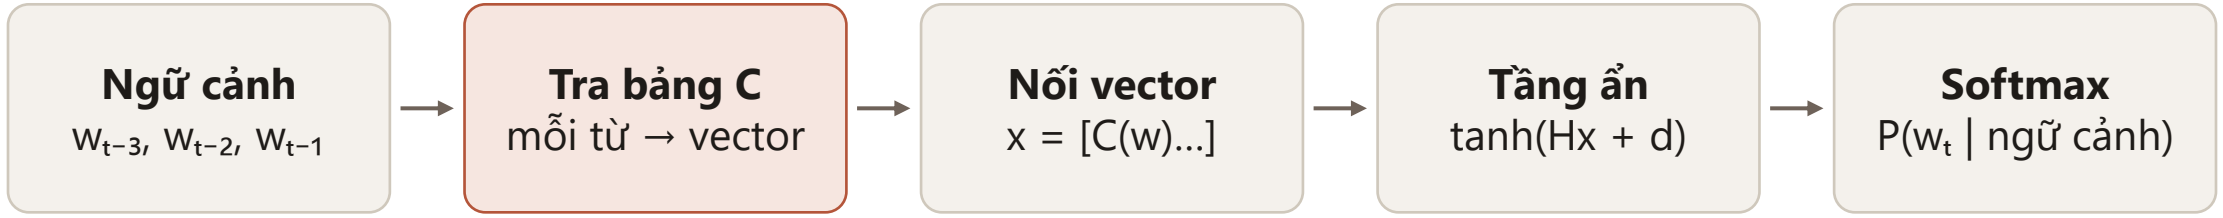
Học word vector bằng cách dự đoán ngữ cảnh

- **Ý tưởng** là đưa thông tin về ngữ cảnh vào vector của từ.
- **Cách làm** là học vector bằng cách huấn luyện mô hình dự đoán các từ ngữ cảnh.
- Hướng tiếp cận này kế thừa một chuỗi nghiên cứu về mạng nơ-ron cho ngôn ngữ:

Năm	Công trình
1986	Rumelhart và cộng sự: học biểu diễn bằng lan truyền ngược sai số
2003	Bengio và cộng sự: mô hình ngôn ngữ xác suất dùng mạng nơ-ron
2008	Collobert và Weston: kiến trúc thống nhất cho NLP với mạng nơ-ron đa nhiệm
2013	Mikolov và cộng sự: word2vec, mô hình đơn giản và nhanh hơn

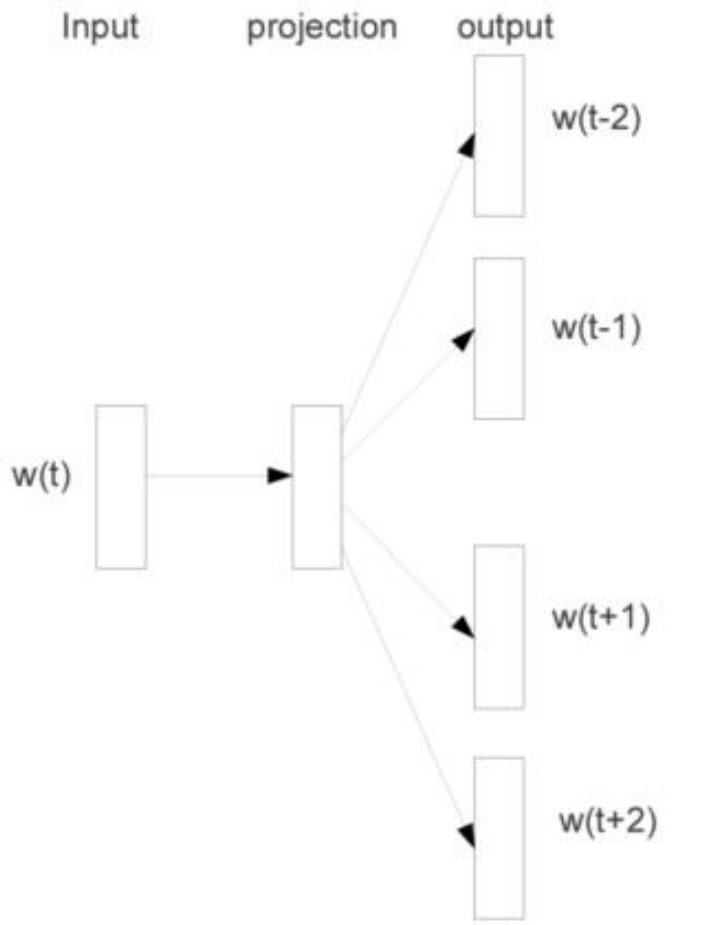
Mô hình ngôn ngữ nơ-ron của Bengio (2003)

- Mô hình dự đoán **từ tiếp theo** dựa trên n − 1 từ đứng trước nó.
- Mỗi từ được tra trong một **bảng embedding C** dùng chung, sau đó các vector được nối lại và đưa qua tầng ẩn tanh và tầng softmax.
- Bảng C được học cùng mô hình, vì vậy **word vector là sản phẩm phụ** của việc học mô hình ngôn ngữ.
- Softmax trên toàn bộ từ vựng và tầng ẩn phi tuyến làm mô hình **huấn luyện chậm**; word2vec đơn giản hóa chính điểm này.



Tổng quan về word2vec

- **Word2vec** (Mikolov và cộng sự, 2013) là một khung phương pháp để học word vector.
- Đầu vào là một ngữ liệu lớn, tức một danh sách dài các từ.
- Mỗi từ trong một từ vựng cố định được biểu diễn bằng **một vector**.
- Mô hình duyệt từng vị trí t trong văn bản, gồm một **từ trung tâm c** và các **từ ngữ cảnh o**.
- Độ tương đồng giữa vector của c và o được dùng để tính **xác suất của o khi biết c** (hoặc ngược lại).
- Các word vector được **điều chỉnh liên tục** để cực đại hóa xác suất này.



Skip-gram model
(Mikolov et al. 2013)

Họ thuật toán word2vec

- Mỗi từ có **hai vector** để tối ưu dễ hơn, và hai vector được **lấy trung bình** khi kết thúc; cũng có thể dùng một vector cho mỗi từ, cách này cho kết quả tốt hơn một chút.

Thành phần	Mô tả
Biến thể 1: Skip-gram (SG)	Dự đoán các **từ ngữ cảnh** (không phụ thuộc vị trí) khi biết từ trung tâm
Biến thể 2: CBOW	Dự đoán **từ trung tâm** từ túi các từ ngữ cảnh
Mất mát 1: naive softmax	Đơn giản nhưng **tốn kém** khi có nhiều lớp đầu ra
Mất mát 2: hierarchical softmax	Biến thể **tối ưu hơn** của softmax
Mất mát 3: negative sampling	Phân biệt cặp thật với **các cặp nhiễu**

- Các slide tiếp theo trình bày lần lượt CBOW, skip-gram và các hàm mất mát thay cho naive softmax.

Ví dụ cửa sổ và cách tính $P(w_{t+j} \mid w_t)$

- Cửa sổ kích thước 2 quanh từ trung tâm "into" tại vị trí t trong câu "… problems turning into banking crises as …".

t – 2	t – 1	t	t + 1	t + 2
problems	turning	**into**	banking	crises
Từ ngữ cảnh	Từ ngữ cảnh	**Từ trung tâm**	Từ ngữ cảnh	Từ ngữ cảnh

$$P(w_{t-2} \mid w_t) \quad P(w_{t-1} \mid w_t) \quad P(w_{t+1} \mid w_t) \quad P(w_{t+2} \mid w_t)$$

$P(u_problems \mid v_into)$ là cách viết tắt của $P(problems \mid into; u_problems, v_into, \theta)$

- Sau đó cửa sổ **dịch sang vị trí tiếp theo**, từ "banking" trở thành từ trung tâm và quá trình tính xác suất được lặp lại.

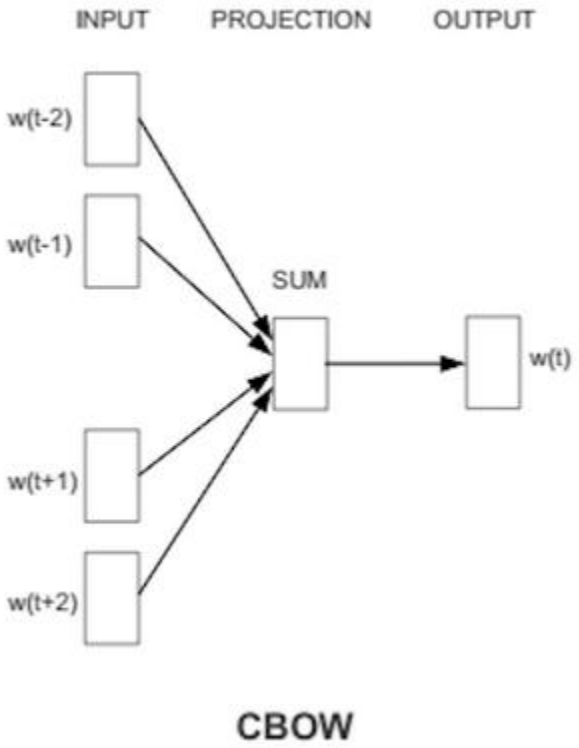
CBOW và skip-gram

- Hai từ có **ngữ cảnh tương tự** thì mô hình phải đưa ra dự đoán ngữ cảnh tương tự cho cả hai từ.
- Cách đơn giản nhất để mạng làm được điều đó là gán cho hai từ **các vector gần nhau**.
- Word2vec có hai phiên bản, khác nhau ở chiều dự đoán giữa từ trung tâm và ngữ cảnh.

	CBOW	**Skip-gram**
Dự đoán	Từ trung tâm từ các từ ngữ cảnh	Các từ ngữ cảnh từ từ trung tâm
Ví dụ (cửa sổ 2)	{the, cat, on, floor} → sat	sat → {the, cat, on, floor}
Đặc điểm	Huấn luyện nhanh, tốt với từ phổ biến	Tốt với dữ liệu nhỏ và từ hiếm

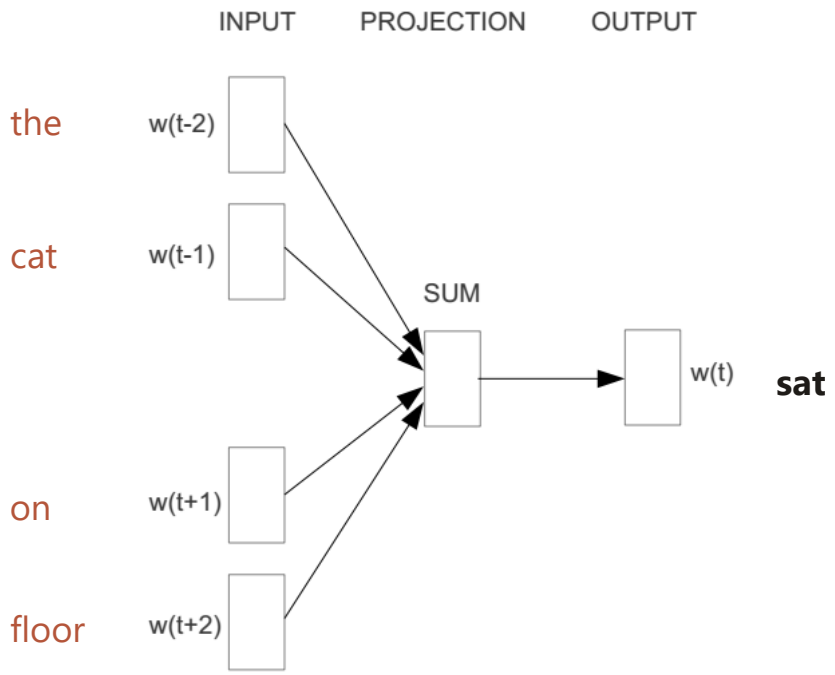
CBOW: dự đoán từ trung tâm từ ngữ cảnh

- Mô hình **bag of words** bỏ qua thứ tự từ và biểu diễn văn bản bằng số lần xuất hiện của từng từ.
- **CBOW** lấy vector của n từ đứng trước và n từ đứng sau từ đích, rồi lấy trung bình chúng thành một vector duy nhất.
- CBOW cũng bỏ qua thứ tự từ, nhưng vector trung bình của ngữ cảnh vẫn đủ thông tin để suy ra từ bị thiếu.



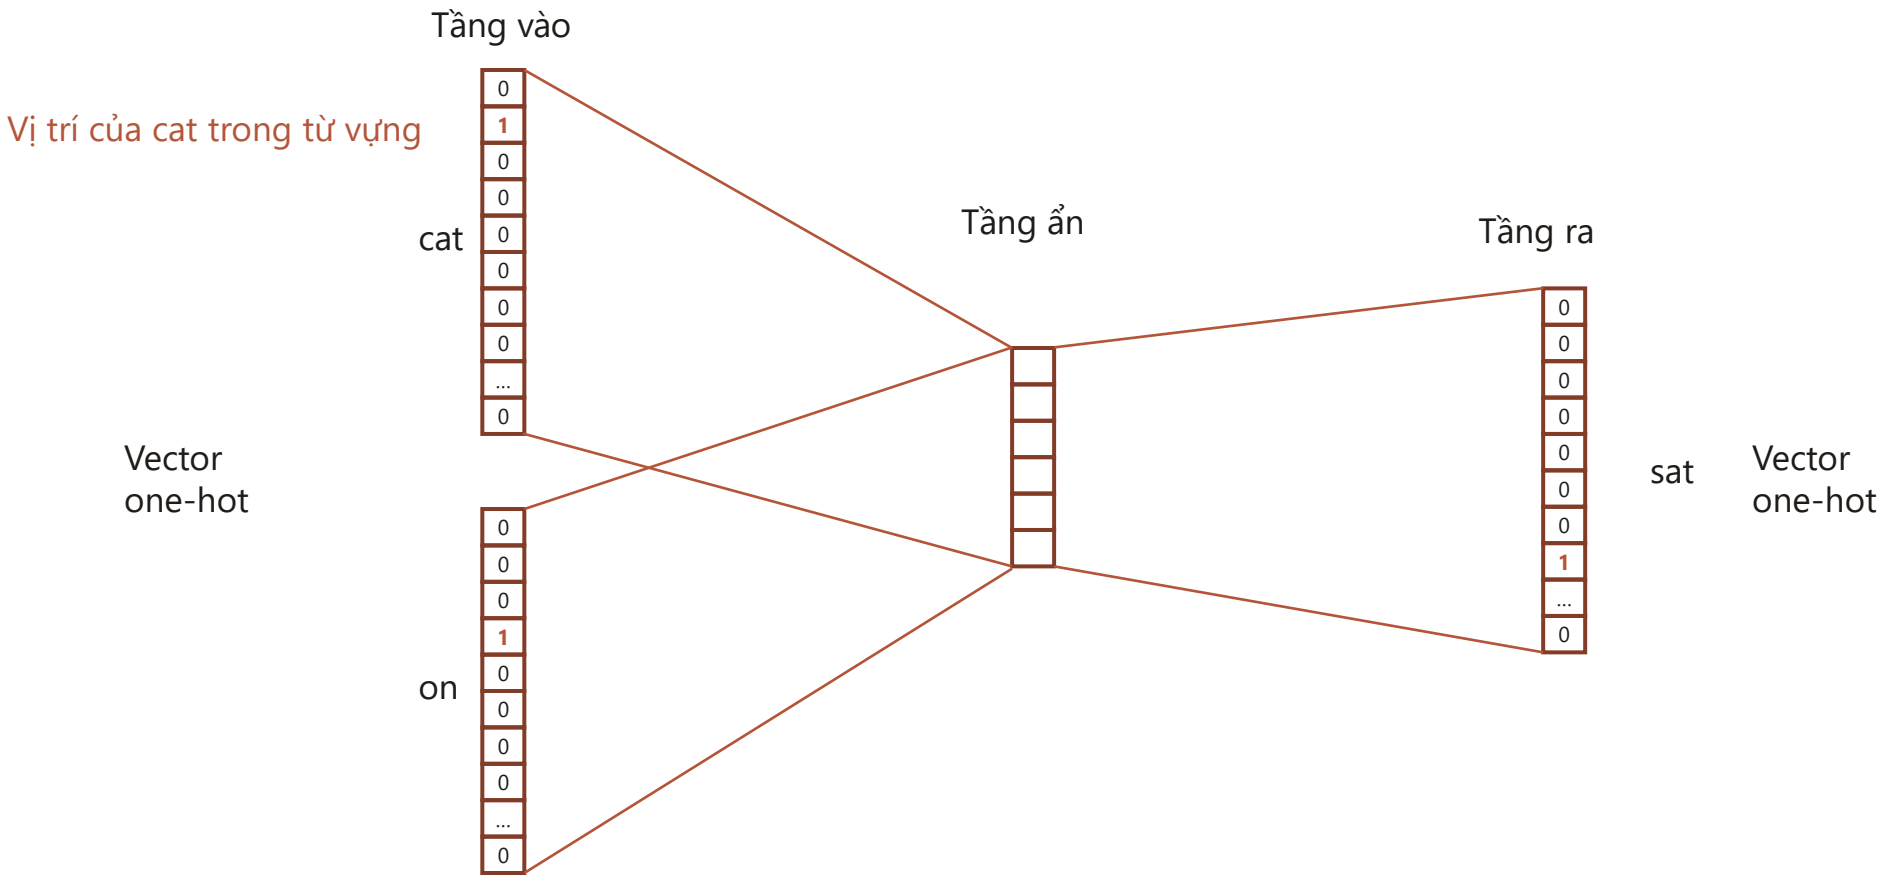
Ví dụ CBOW với cửa sổ kích thước 2

- Với câu "The cat sat on floor" và cửa sổ kích thước 2, CBOW dùng bốn từ **the, cat, on, floor** để dự đoán từ trung tâm **sat**.

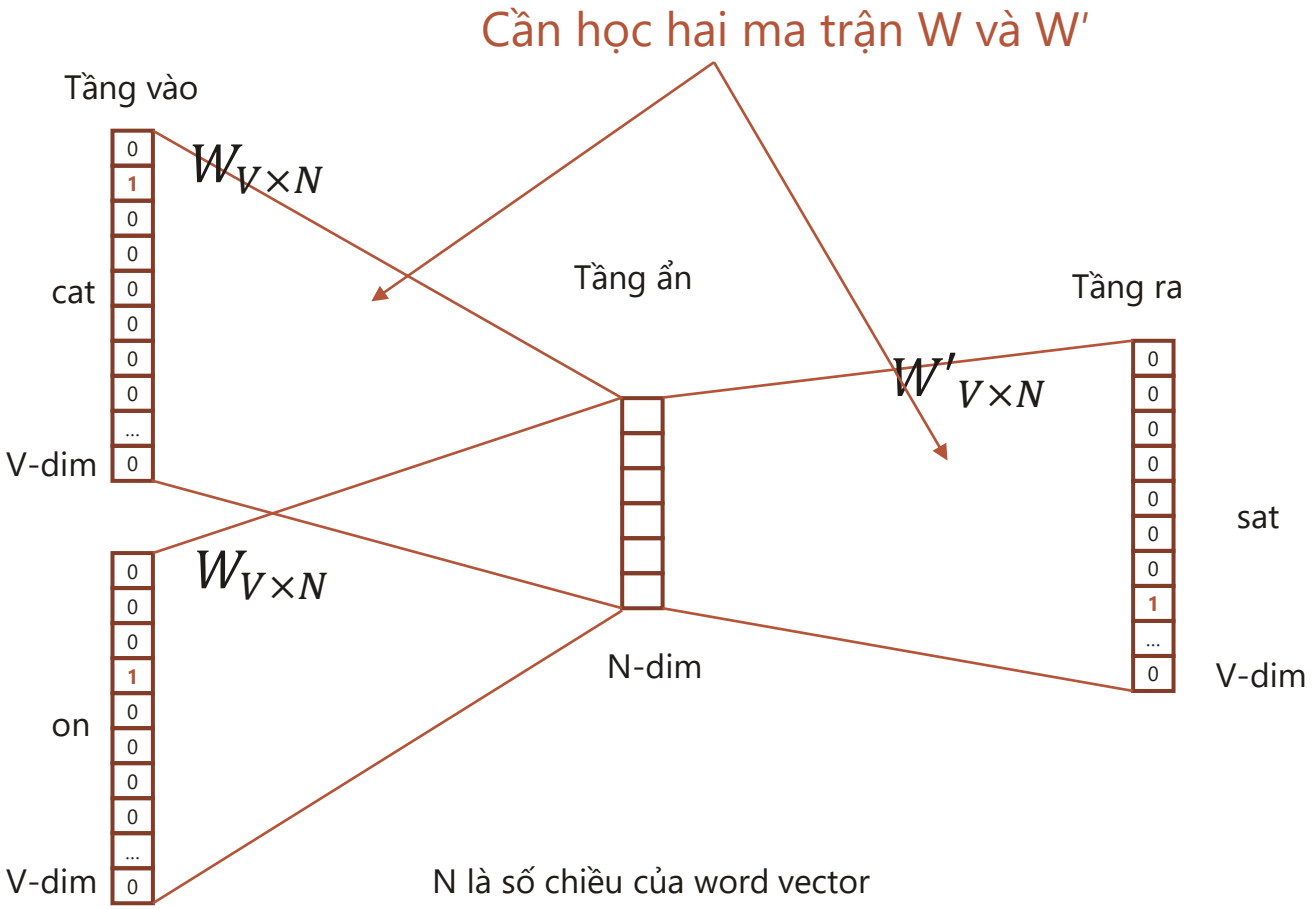


Nguồn: www.cs.ucr.edu/~vagelis/classes/CS242/slides/word2vec.pptx

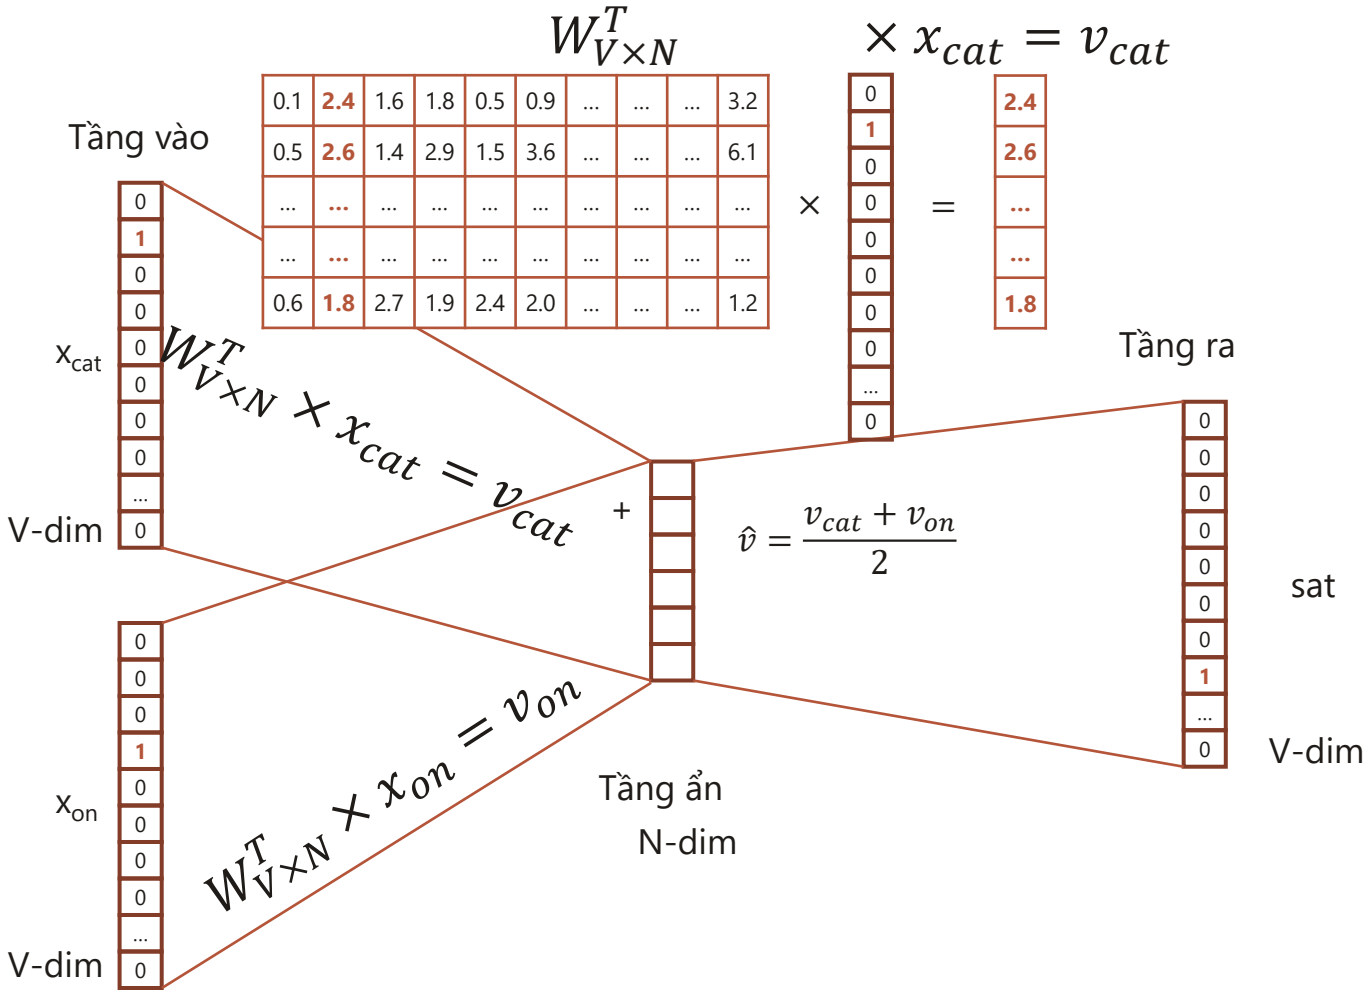
Đầu vào của CBOW là vector one-hot



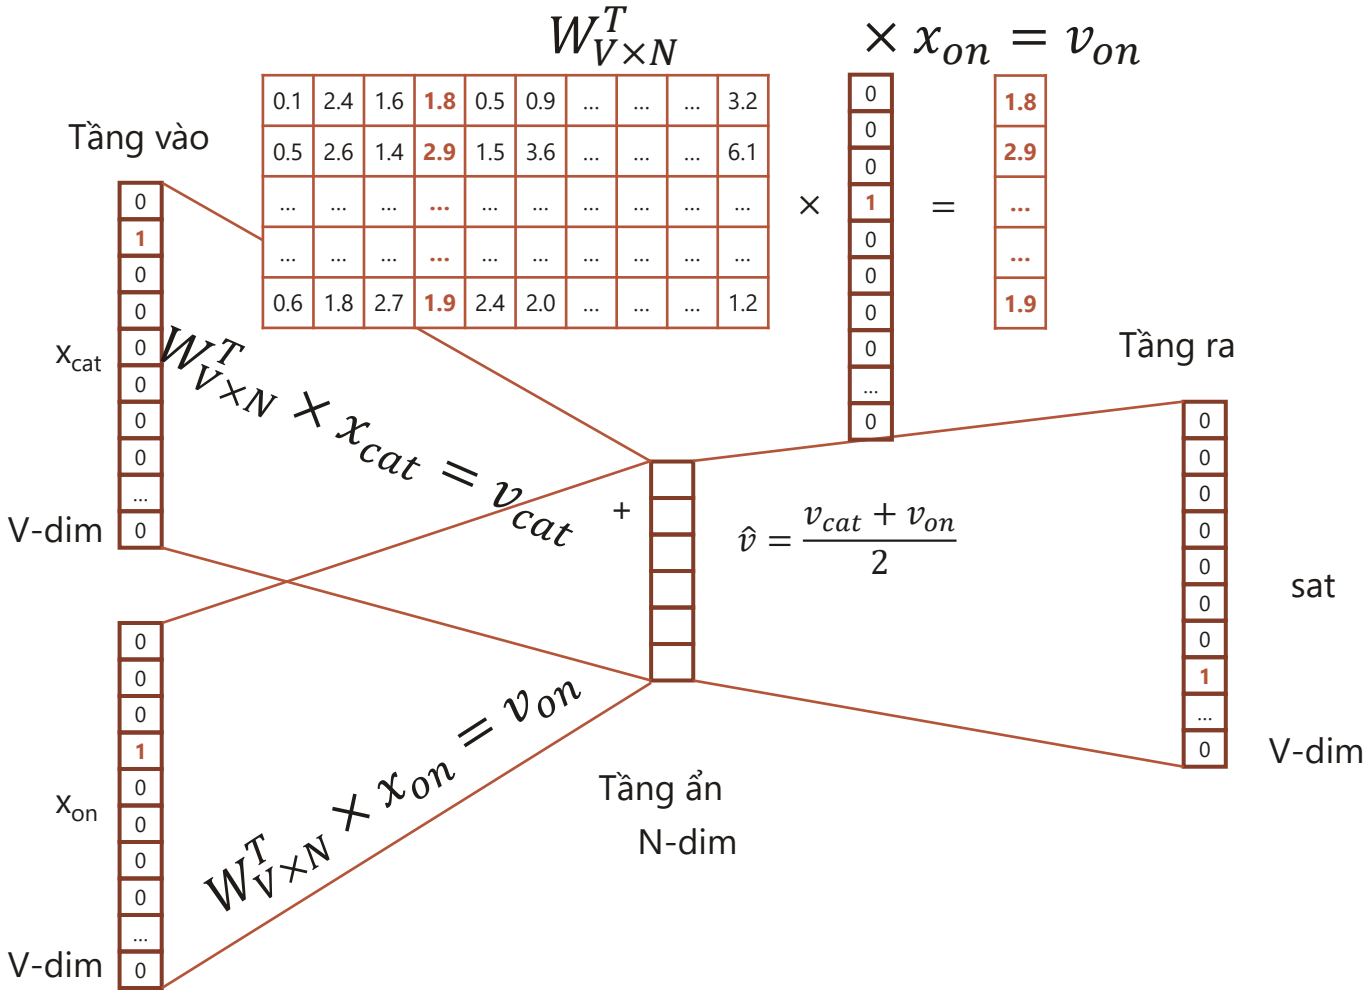
CBOW cần học hai ma trận W và W'



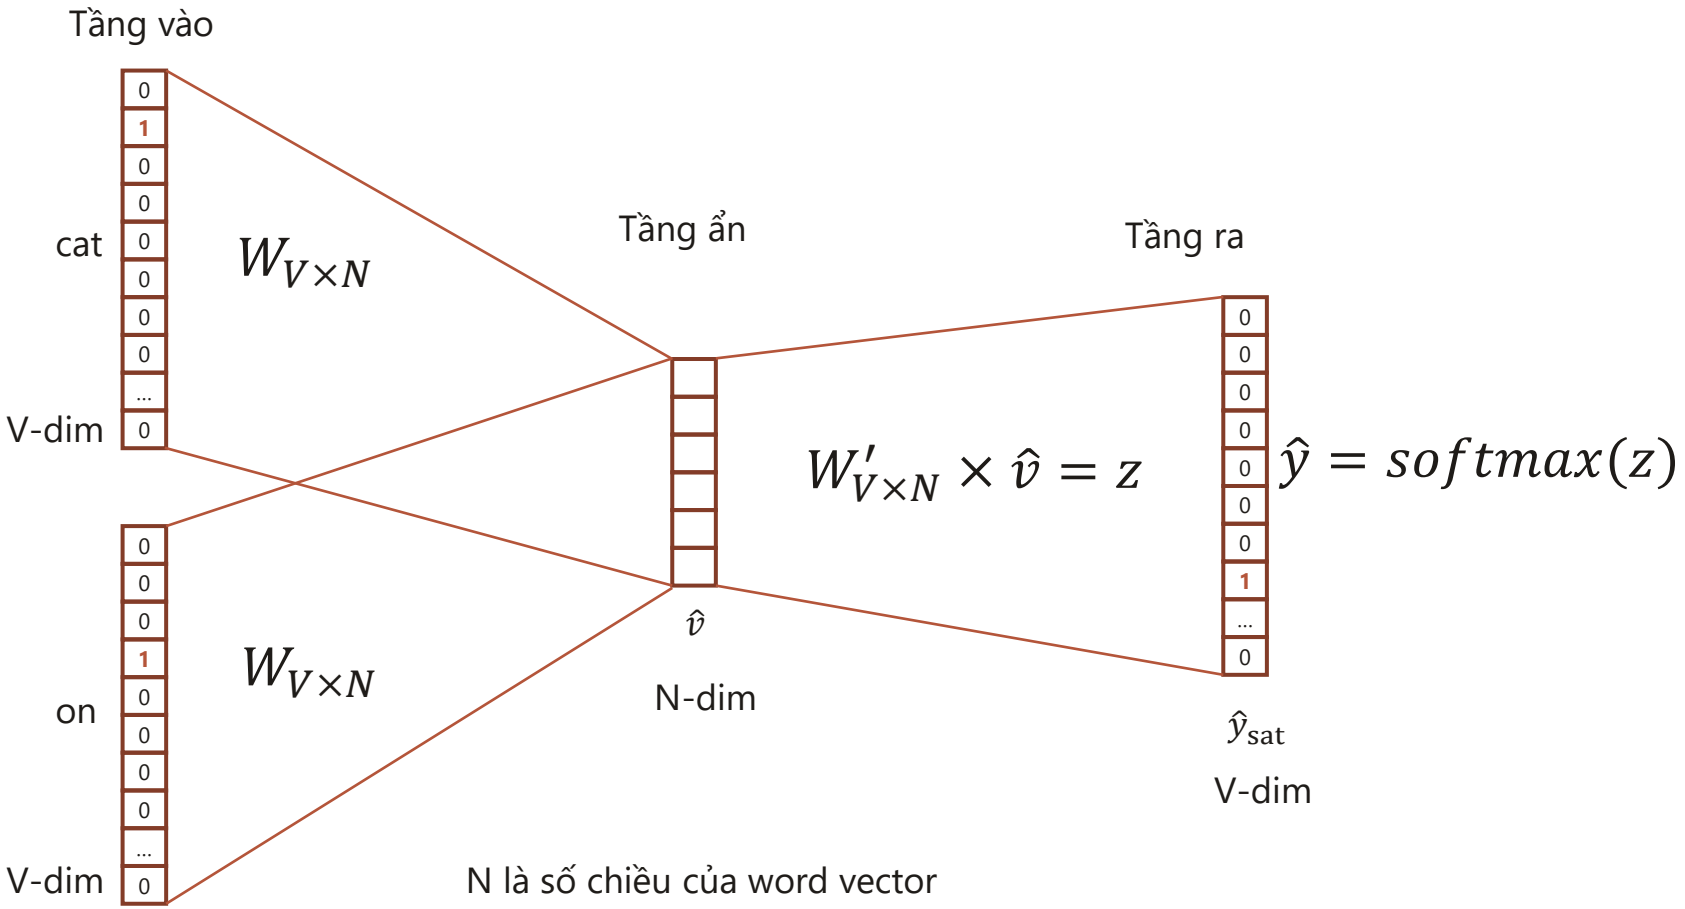
Tầng ẩn lấy vector của cat từ ma trận W



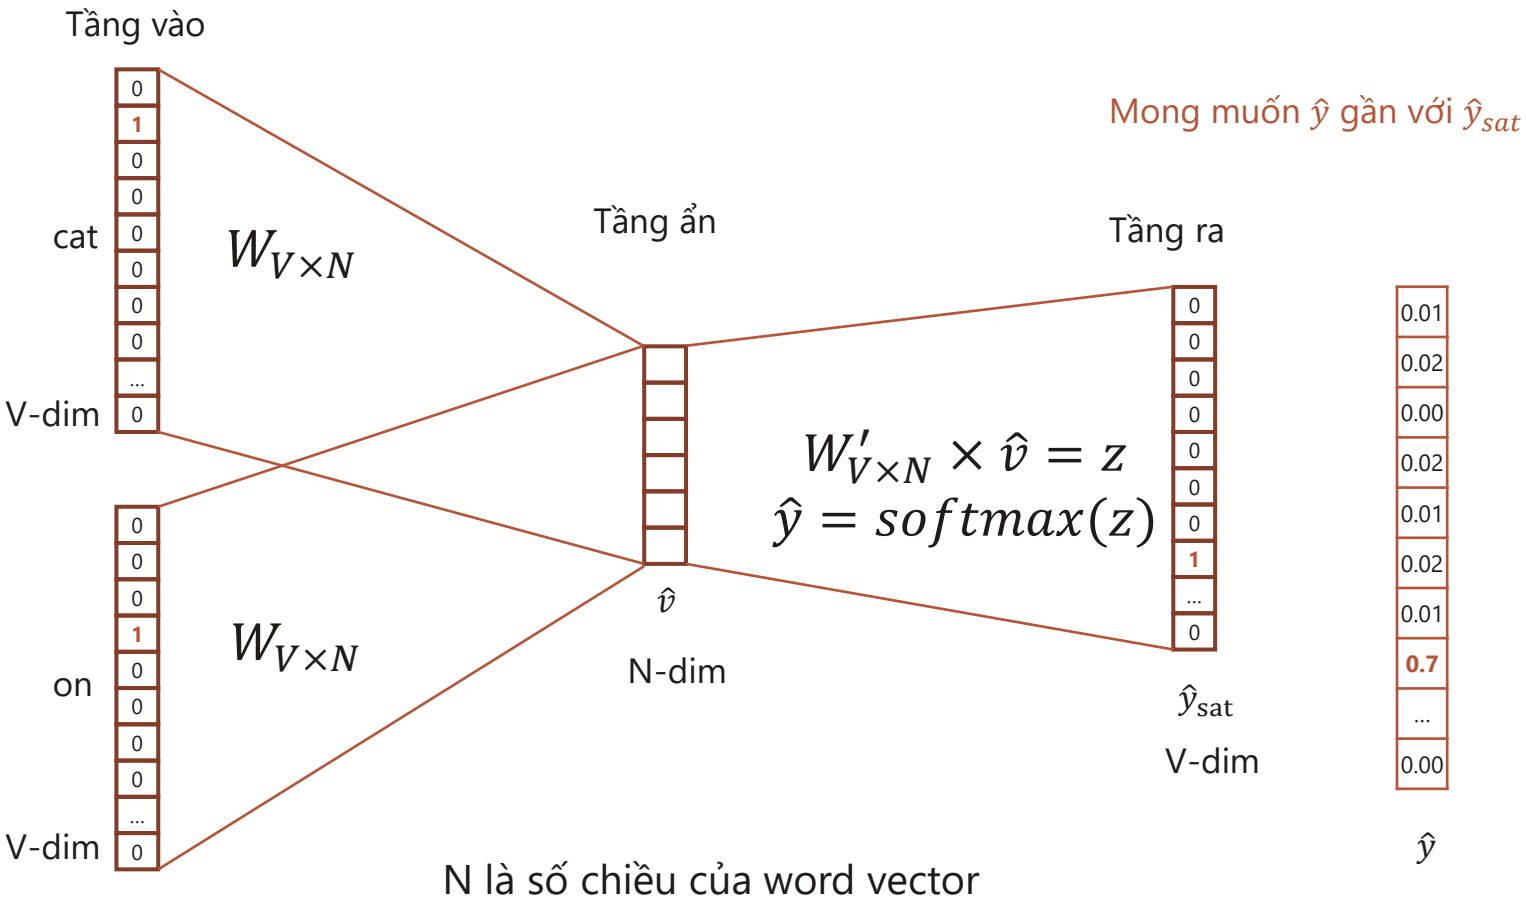
Tầng ẩn lấy trung bình vector của cat và on



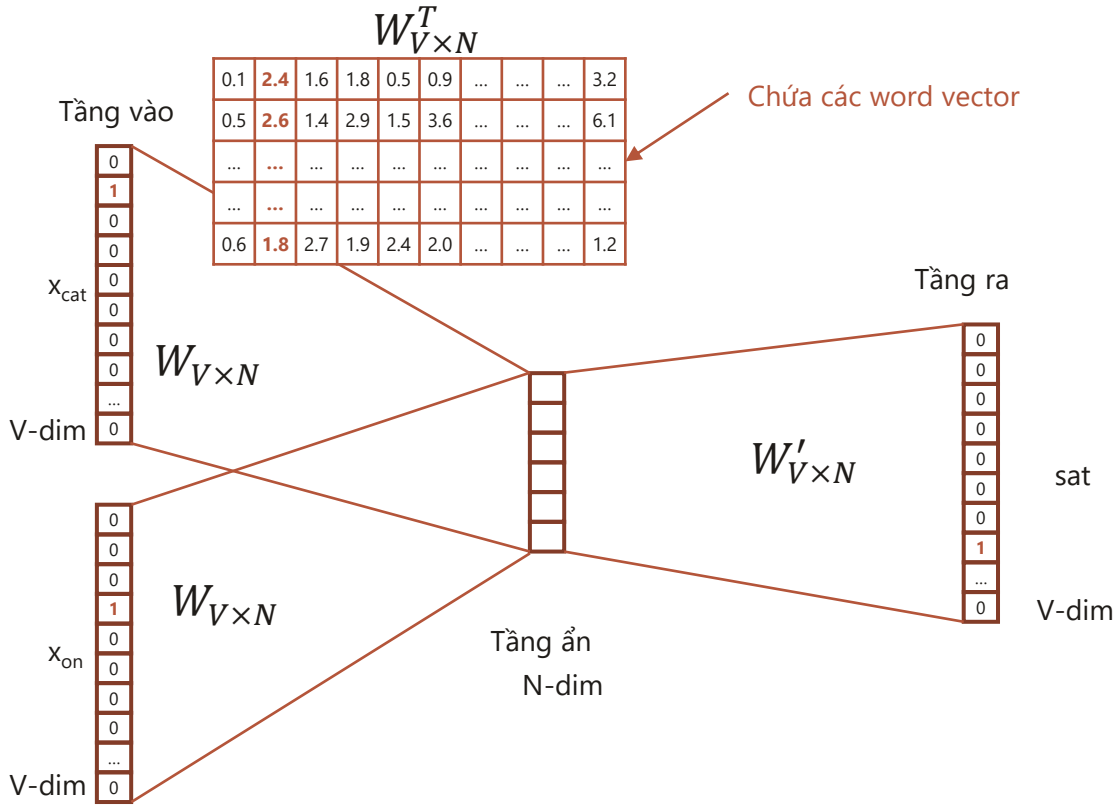
Tầng ra dùng softmax để dự đoán từ trung tâm



Huấn luyện để ŷ gần với vector one-hot của sat



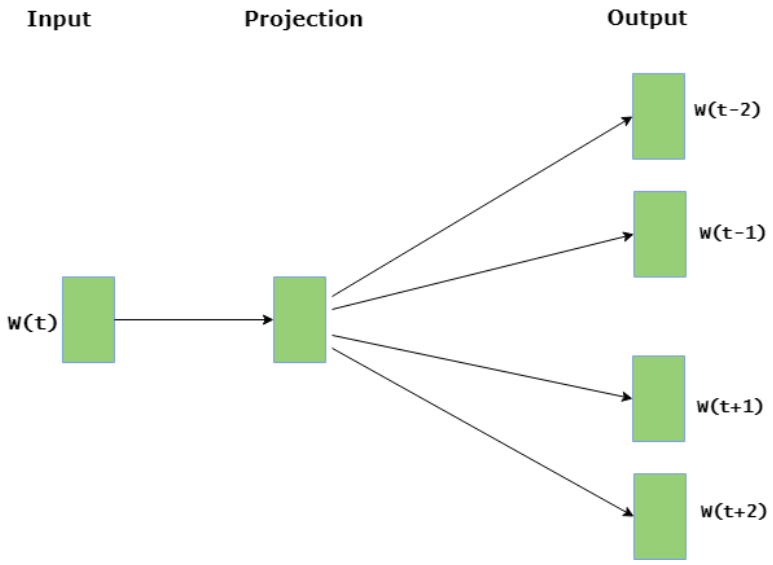
Các hàng của ma trận W chính là word vector



Có thể xem **W là biểu diễn của các từ**.

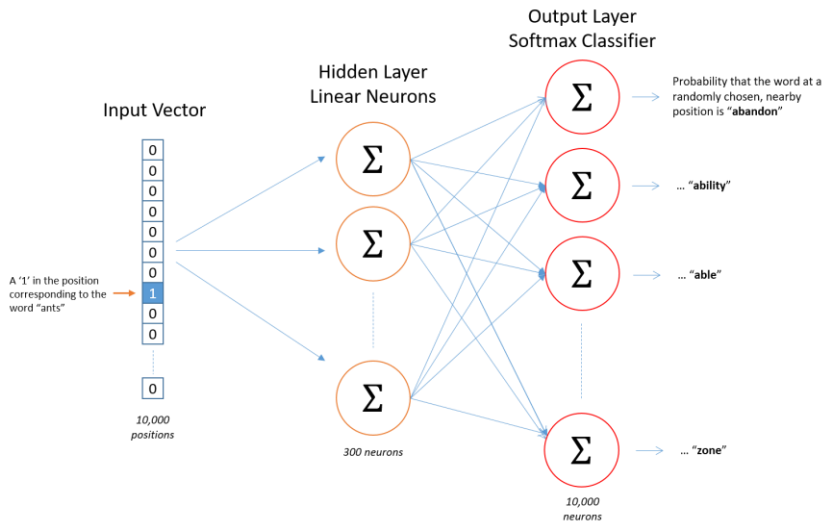
Skip-gram: dự đoán ngữ cảnh từ từ trung tâm

- **Skip-gram** là phương án thay thế CBOW: mô hình bắt đầu từ vector của một từ trung tâm và dự đoán các **từ ngữ cảnh** xung quanh.
- Skip-gram hoạt động tốt với **tập dữ liệu nhỏ** và biểu diễn tốt hơn các **từ ít xuất hiện**.



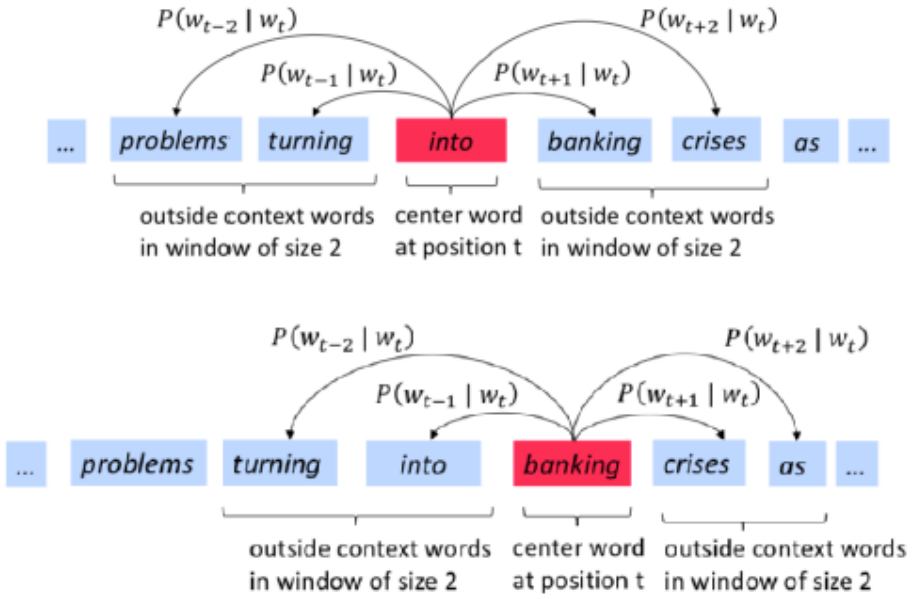
Skip-gram: tầng ẩn tuyến tính, tầng ra softmax

- Mạng ánh xạ **từ trung tâm** thành **phân phối xác suất** trên các từ xung quanh; hình dưới minh họa một cặp đầu vào và đầu ra.
- Các nơ-ron tầng ẩn **không dùng hàm kích hoạt**, còn các nơ-ron tầng ra dùng **softmax**.



Nguồn: mccormickml.com/2016/04/19/word2vec-tutorial-the-skip-gram-model/

Skip-gram sinh cặp huấn luyện từ cửa sổ ngữ cảnh



Convert into training data:

(into, problems)
(into, turning)
(into, banking)
(into, crises)
(banking, turning)
(banking, into)
(banking, crises)
(banking, as)
…

Our goal is to find parameters that can maximize

$P(\text{problems} \mid \text{into}) \times P(\text{turning} \mid \text{into}) \times P(\text{banking} \mid \text{into}) \times P(\text{crises} \mid \text{into}) \times$

$P(\text{turning} \mid \text{banking}) \times P(\text{into} \mid \text{banking}) \times P(\text{crises} \mid \text{banking}) \times P(\text{as} \mid \text{banking}) \ldots$

Hàm mục tiêu của skip-gram

- For each position $t = 1,2,\ldots T$, predict context words within context size m, given center word w_t:

$$\mathcal{L}(\theta) = \prod_{t=1}^{T} \prod_{-m \le j \le m, j \neq 0} P(w_{t+j} \mid w_t; \theta)$$

all the parameters to be optimized

- It is equivalent to minimizing the (average) negative log likelihood:

$$J(\theta) = -\frac{1}{T} \log \mathcal{L}(\theta) = -\frac{1}{T} \sum_{t=1}^{T} \sum_{-m \le j \le m, j \neq 0} \log P(w_{t+j} \mid w_t; \theta)$$

Hàm mất mát cho cặp từ (cat, cute)

$$\text{Loss} = J(\theta) = -\frac{1}{T}\log L(\theta) = -\frac{1}{T}\sum_{t=1}^{T}\sum_{-m\le j\le m, j\neq 0}\log P(w_{t+j}|w_t,\theta) = \frac{1}{T}\sum_{t=1}^{T}\sum_{-m\le j\le m, j\neq 0} J_{t,j}(\theta).$$

... I saw a cute grey cat playing in the garden ...

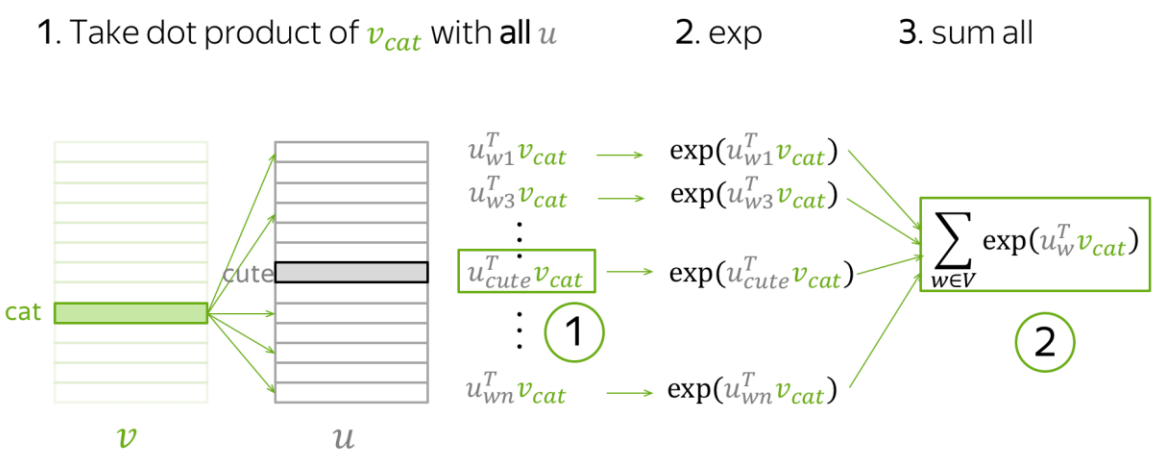
with the central word cat, and four context words. Since we are going to look at just one step, we will pick only one of the context words; for example, let's take cute. Then the loss term for the central word cat and the context word cute is:

$$J_{t,j}(\theta) = -\log P(cute|cat) = -\log\frac{\exp u_{cute}^T v_{cat}}{\sum_{w\in Voc}\exp u_w^T v_{cat}} = -u_{cute}^T v_{cat} + \log\sum_{w\in Voc}\exp u_w^T v_{cat}.$$

Note which parameters are present at this step:

- from vectors for central words, only v_{cat};
- from vectors for context words, all u_w (for all words in the vocabulary).

Một bước cập nhật gradient cho cặp (cat, cute)



4. get loss (for this one step)

$$J_{t,j}(\theta) = -\underbrace{u_{cute}^T v_{cat}}_{1} + \underbrace{\log \sum_{w \in V} \exp(u_w^T v_{cat})}_{2}$$

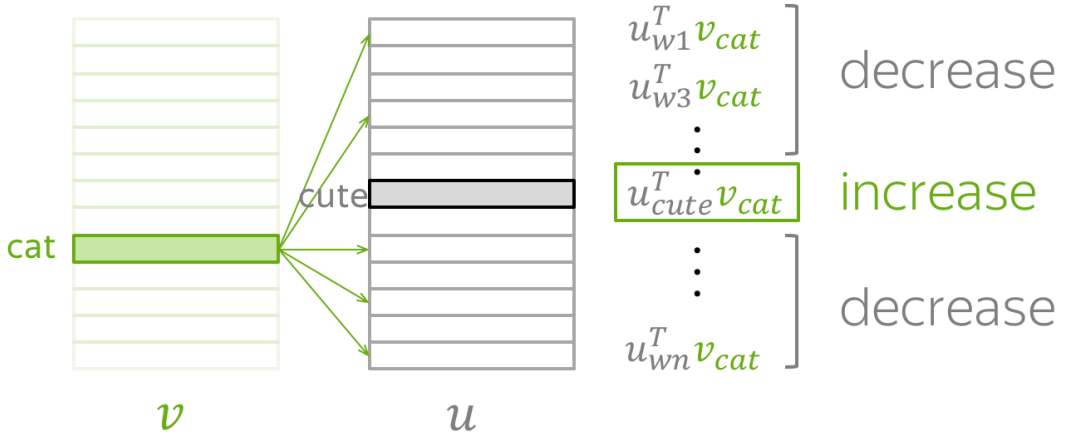
5. evaluate the gradient, make an update

$$v_{cat} := v_{cat} - \alpha \frac{\partial J_{t,j}(\theta)}{\partial v_{cat}}$$

$$u_w := u_w - \alpha \frac{\partial J_{t,j}(\theta)}{\partial u_w} \quad \forall w \in \mathrm{V}$$

Cập nhật làm tăng độ tương đồng với từ ngữ cảnh

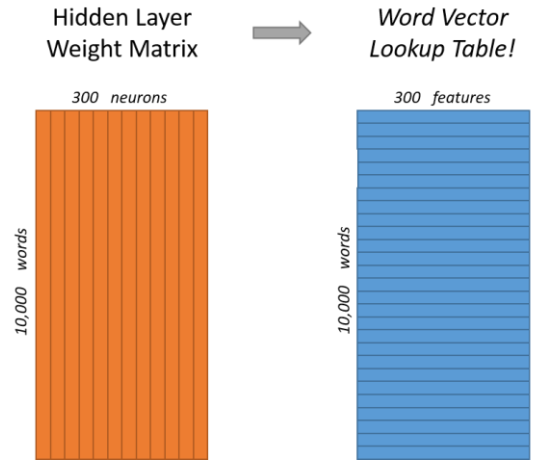
By making an update to minimize $J_{t,j}(\theta)$, we force the parameters to increase similarity (dot product) of v_{cat} and u_{cute} and, at the same time, to decrease similarity between v_{cat} and u_w for all other words w in the vocabulary.



Ví dụ skip-gram: 10.000 từ, vector 300 chiều

- Từ vựng gồm **10.000 từ**, và mỗi word vector có **300 chiều**.
- Tầng ẩn là một **ma trận trọng số 10.000 × 300**; nhân vector one-hot với ma trận này chính là lấy ra một hàng của ma trận.
- Ma trận trọng số tầng ẩn vì vậy đóng vai trò **bảng tra word vector**.

$$[0 \quad 0 \quad 0 \quad 1 \quad 0] \times \begin{bmatrix} 17 & 24 & 1 \\ 23 & 5 & 7 \\ 4 & 6 & 13 \\ 10 & 12 & 19 \\ 11 & 18 & 25 \end{bmatrix} = [10 \quad 12 \quad 19]$$



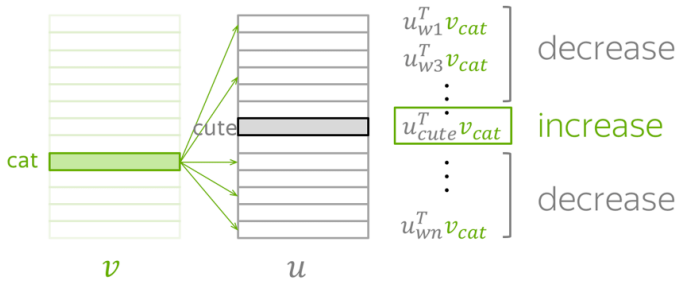
Nguồn: mccormickml.com/2016/04/19/word2vec-tutorial-the-skip-gram-model/

Softmax đầy đủ khiến word2vec huấn luyện chậm

- Với **10.000 từ** và vector **300 chiều**, mô hình đã có không gian tham số lớn, trong khi 10.000 từ chỉ là quy mô tối thiểu của ứng dụng thực tế.
- Mỗi tầng có một ma trận trọng số **300 × 10.000 = 3 triệu trọng số**.
- Mô hình vì vậy **huấn luyện chậm** và cần nhiều dữ liệu, nhất là để học các **từ ít xuất hiện**.

Negative sampling chỉ cập nhật từ dương và K từ âm

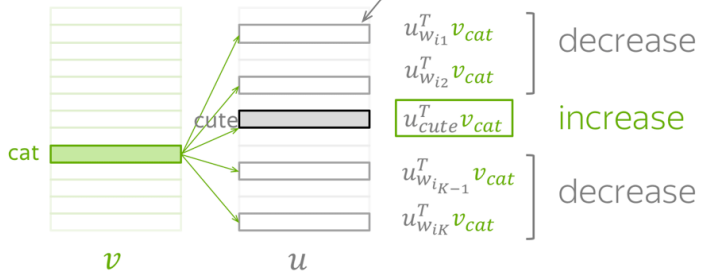
Dot product of v_{cat}:
- with u_{cute} - increase,
- with <u>all other</u> u - decrease



Parameters to be updated:
- v_{cat}
- u_w for all w in the vocabulary — |V| + 1 vectors

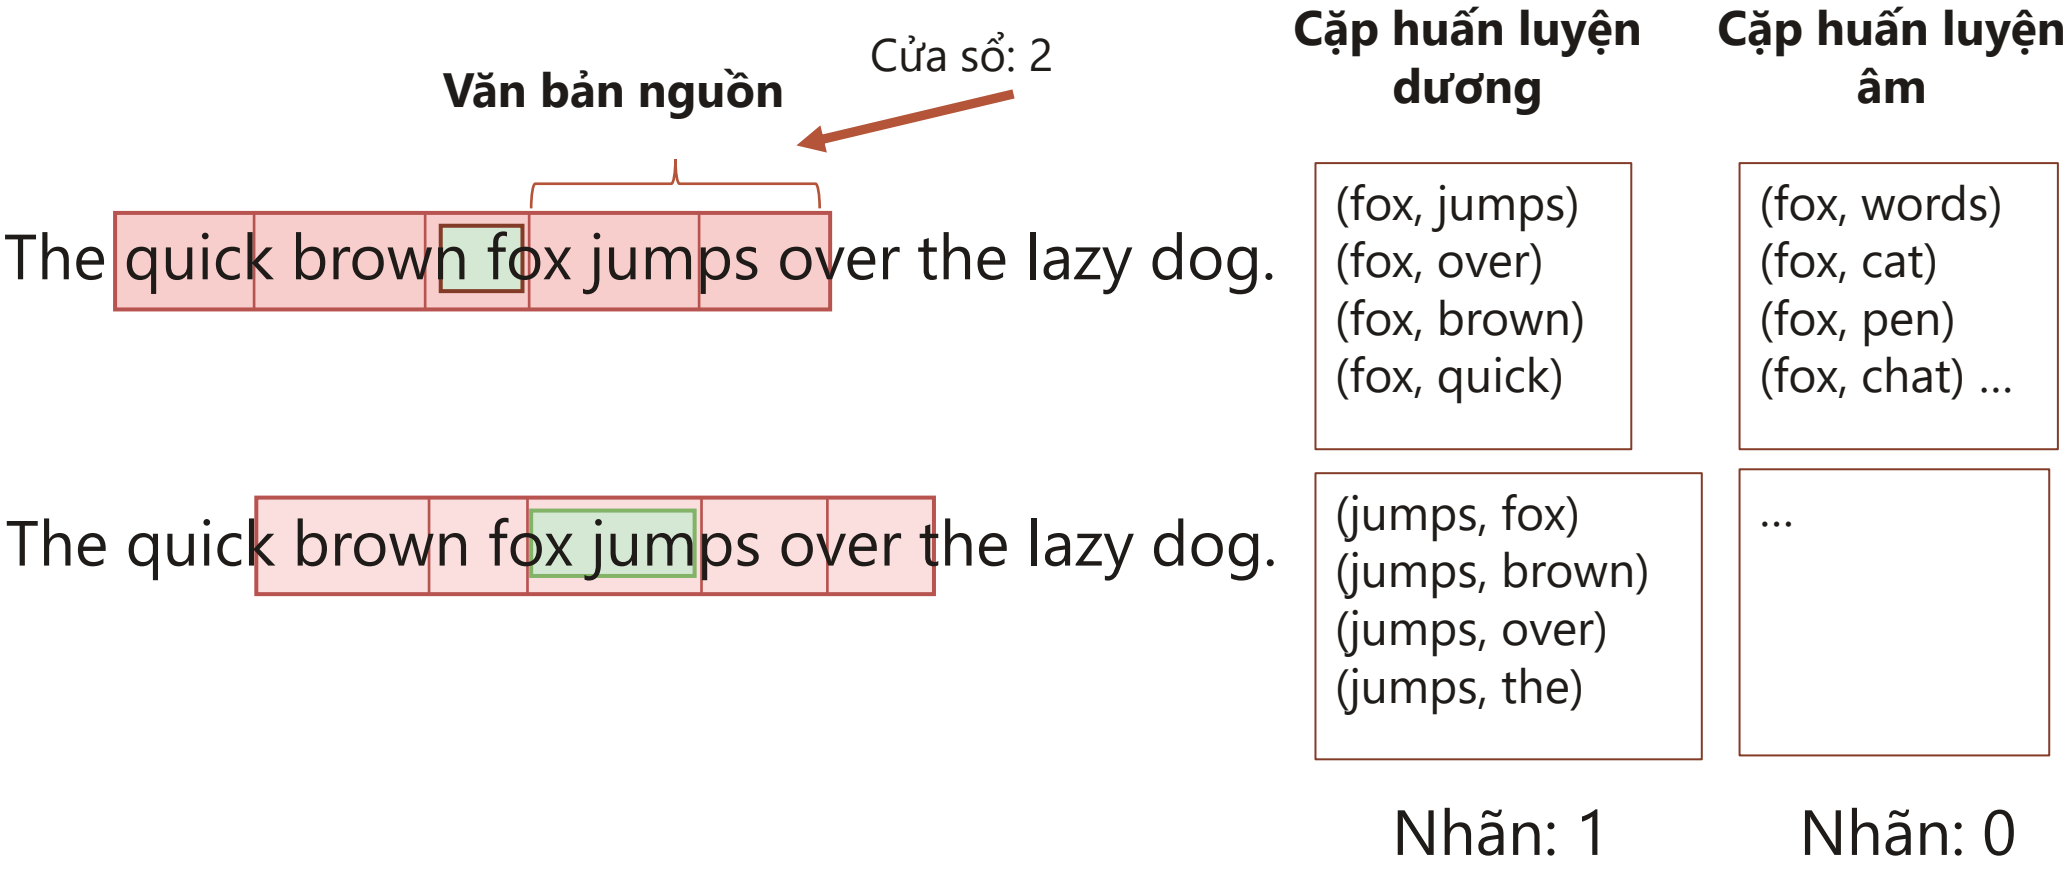
Dot product of v_{cat}:
- with u_{cute} - increase,
- with <u>a subset of other</u> u - decrease

<u>Negative samples</u>: randomly selected K words



Parameters to be updated:
- v_{cat}
- u_{cute} and u_w for w in K negative examples — K + 2 vectors

Cặp dương và cặp âm sinh từ cửa sổ ngữ cảnh



Mỗi bước chỉ cập nhật 0,06% trọng số tầng ra

- Chọn **5–20 từ âm** phù hợp với tập dữ liệu nhỏ, còn tập dữ liệu lớn chỉ cần **2–5 từ âm**.
- Mỗi bước chỉ cập nhật trọng số của từ dương “jumps” và 5 từ âm có đầu ra mong muốn bằng 0, tức **6 nơ-ron đầu ra và 1.800 trọng số**.
- Số trọng số này chỉ bằng **0,06% của 3 triệu trọng số** ở tầng ra.

GloVe mã hóa nghĩa bằng tỉ lệ đồng xuất hiện

- GloVe dựa trên nhận xét rằng **tỉ lệ giữa các xác suất đồng xuất hiện** của hai từ có thể mã hóa một phần ý nghĩa.
- Từ **ice** xuất hiện cùng **solid** thường xuyên hơn **gas**, còn từ **steam** xuất hiện cùng **gas** thường xuyên hơn **solid**.
- Cả hai từ đều thường xuất hiện cùng thuộc tính chung **water** và hiếm khi xuất hiện cùng từ không liên quan **fashion**.
- Vì vậy, tỉ lệ P(k | ice) / P(k | steam) **lớn hoặc nhỏ** với từ phân biệt và **xấp xỉ 1** với từ trung tính.

So sánh word2vec và GloVe

- Ưu điểm chính của GloVe là kết hợp **thống kê toàn cục** của ma trận đồng xuất hiện với cách học vector dày đặc của các mô hình dự đoán.

Tiêu chí	word2vec	GloVe
Thông tin sử dụng	Ngữ cảnh cục bộ trong từng cửa sổ	Số đếm đồng xuất hiện trên toàn ngữ liệu
Cách học	Dự đoán ngữ cảnh bằng SGD, duyệt ngữ liệu nhiều lần	Bình phương tối thiểu có trọng số trên các ô khác 0 của X
Chi phí	Tỉ lệ với kích thước ngữ liệu	Một lần đếm X ban đầu, sau đó tỉ lệ với số ô khác 0
Kết quả	Tốt ở bài toán tương tự và độ tương đồng	Tốt tương đương hoặc hơn, huấn luyện nhanh trên ngữ liệu lớn

fastText: biểu diễn từ bằng n-gram ký tự

- **fastText** do Facebook công bố năm 2016, mở rộng skip-gram với negative sampling.
- Mỗi từ được biểu diễn bằng **tổng các vector n-gram ký tự** (n từ 3 đến 6) của nó cùng vector của chính từ đó: $v_w = \sum_{g \in G_w} z_g$.
- Nhờ vậy fastText tạo được vector cho **từ ngoài từ vựng** và học tốt hơn với từ hiếm và ngôn ngữ giàu hình thái.

Thành phần	Ví dụ với từ “where”, n = 3
Từ thêm ký hiệu biên < và >	<where>
Các 3-gram ký tự	“<wh”, “whe”, “her”, “ere”, “re>”
Vector của từ	tổng vector của 5 n-gram và của <where>

Tính chất của word embedding

- Embedding là một hàm W(từ) trả về vector mã hóa từ đó.
- **Từ tương tự nằm gần nhau** trong không gian vector, ví dụ director – chairman, scratched – scraped.
- **Quan hệ giữa các từ tương ứng với hiệu vector**, nên có thể giải bài toán tương tự (analogy) bằng phép cộng trừ vector.

Quan hệ	Phép tính vector	Kết quả gần nhất
Giới tính	king − man + woman	queen
Thủ đô	Paris − France + Italy	Rome
So sánh hơn	bigger − big + small	smaller
Thì quá khứ	walked − walk + swim	swam

Phép loại suy: king – man + woman ≈ queen

Word Analogies

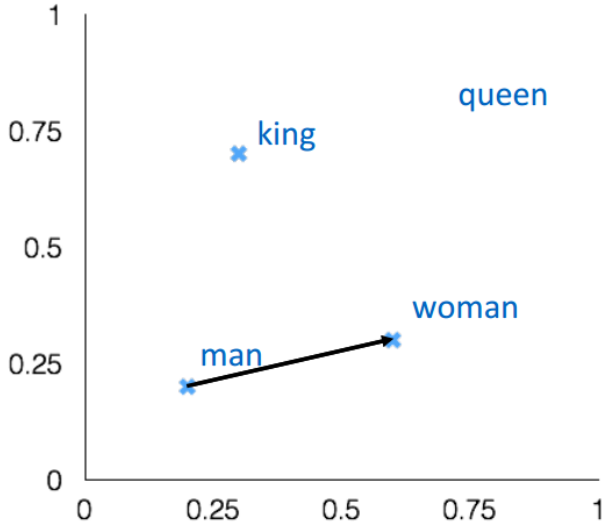
Test for linear relationships, examined by Mikolov et al. (2014)

a:b :: c:?

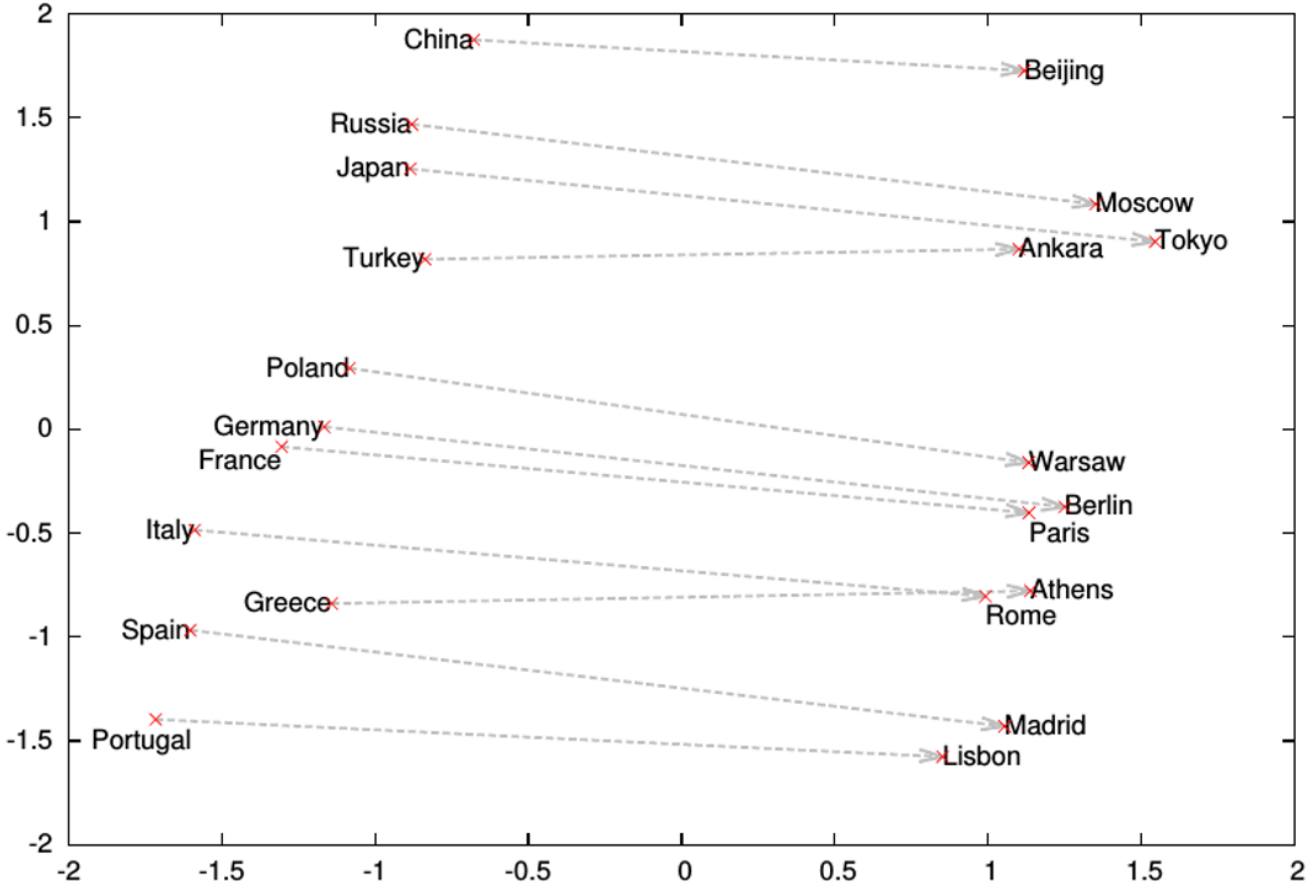
$$d = \arg\max_x \frac{(w_b - w_a + w_c)^T w_x}{||w_b - w_a + w_c||}$$

man:woman :: king:?

+	king	[0.30 0.70]
-	man	[0.20 0.20]
+	woman	[0.60 0.30]
	queen	[0.70 0.80]



Cặp quốc gia – thủ đô tạo các vector song song



Thiên kiến trong word embedding

- Word embedding học cả những **thiên kiến không mong muốn** có trong văn bản huấn luyện.
- Quan hệ **man : woman → king : queen** là mong muốn, nhưng mô hình cũng sinh ra **man : programmer → woman : homemaker**.
- Bolukbasi và cộng sự (2016) biến đổi không gian vector để khử thiên kiến mà vẫn giữ các quan hệ hữu ích.

Bước	Tên bước	Nội dung
1	Xác định hướng	Tìm hướng giới tính từ hiệu các cặp như he − she, man − woman.
2	Trung hòa	Loại thành phần giới tính khỏi các từ trung tính như programmer.
3	Cân bằng	Đặt các cặp như grandmother – grandfather cách đều các từ trung tính.

Trực quan hóa embedding bằng PCA và t-SNE

- Word vector có hàng trăm chiều, nên cần **giảm xuống 2 hoặc 3 chiều** để quan sát các cụm và quan hệ giữa các từ.
- Mọi phép chiếu đều làm mất một phần thông tin, nên quan hệ thấy trên hình 2D chỉ mang tính gợi ý.

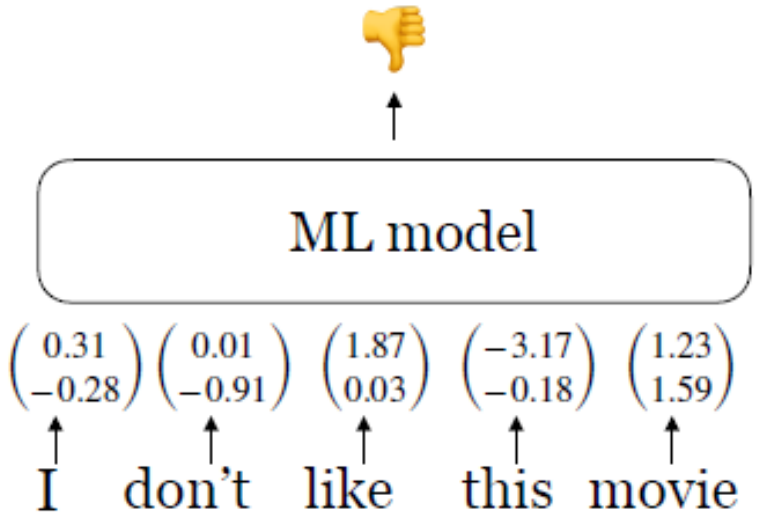
Tiêu chí	PCA	t-SNE
Loại phương pháp	Giảm chiều tuyến tính	Giảm chiều phi tuyến
Nguyên tắc	Giữ lại nhiều phương sai nhất có thể	Giữ các điểm gần nhau vẫn gần nhau khi chiếu
Điểm mạnh	Nhanh, ổn định, kết quả lặp lại được	Làm lộ rõ các cụm từ tương tự
Hạn chế	Khó thể hiện cấu trúc phi tuyến	Chậm hơn; khoảng cách giữa các cụm không đáng tin

Hai cách đánh giá word embedding

- **Đánh giá ngoại tại** đưa word embedding vào một hệ thống NLP thực và đo xem hiệu năng có cải thiện hay không.
- Đánh giá ngoại tại có thể tốn nhiều thời gian nhưng vẫn là **thước đo quan trọng nhất**.
- **Đánh giá nội tại** đo chất lượng embedding trên một tác vụ trung gian cụ thể và **tính toán nhanh**.
- Kết quả đánh giá nội tại **chưa chắc phản ánh** hiệu quả trên các tác vụ thực tế.

Đánh giá ngoại tại trên một hệ thống NLP thực

- Word embedding được đưa vào một mô hình thực, ví dụ **phân loại cảm xúc** câu "I don't like this movie", rồi đo xem hiệu năng có cải thiện hay không.



GloVe 42B đạt điểm tương đồng từ cao nhất

Model	Size	WS353	MC	RG	SCWS	RW
SVD	6B	35.3	35.1	42.5	38.3	25.6
SVD-S	6B	56.5	71.5	71.0	53.6	34.7
SVD-L	6B	65.7	72.7	75.1	56.5	37.0
CBOW†	6B	57.2	65.6	68.2	57.0	32.5
SG†	6B	62.8	65.2	69.7	58.1	37.2
GloVe	6B	65.8	72.7	77.8	53.9	38.1
SVD-L	42B	74.0	76.4	74.1	58.3	39.9
GloVe	42B	**75.9**	**83.6**	**82.9**	**59.6**	**47.8**
CBOW*	100B	68.4	79.6	75.4	59.4	45.5

Ứng dụng của word embedding

- Word embedding là thành phần then chốt giúp cải thiện nhiều hệ thống NLP như **nhận dạng thực thể có tên**, **gán nhãn từ loại**, **phân tích cú pháp** và **gán nhãn vai nghĩa** (Collobert và cộng sự, 2011).
- Học biểu diễn tốt trên tác vụ A rồi dùng cho tác vụ B là nền tảng của **tiền huấn luyện**, **học chuyển giao** và **học đa nhiệm**, và dẫn tới các mô hình ngôn ngữ lớn.
- Embedding có thể học từ nhiều loại dữ liệu, ví dụ StarSpace nhúng mọi đối tượng vào cùng một không gian.
- **Embedding đa phương thức** đặt từ và ảnh vào chung một không gian: ảnh mèo được ánh xạ gần vector của từ “cat”, nên mô hình nhận ra được cả lớp chưa có ảnh huấn luyện.

Embedding tĩnh gộp mọi nghĩa của từ

- **Embedding tĩnh** như word2vec, GloVe và fastText gán **một vector duy nhất** cho mỗi từ, bất kể từ đó xuất hiện trong ngữ cảnh nào.
- Vector của một **từ đa nghĩa** vì vậy là sự pha trộn của mọi nghĩa, thiên về nghĩa xuất hiện nhiều nhất trong ngữ liệu.

Câu	Nghĩa của "bank"
She sat on the bank of the river.	bờ sông (bank.n.01)
He deposited money in the bank.	ngân hàng (bank.n.02)

- Hai câu trên nhận **cùng một vector** cho "bank", nên bài toán **phân giải nghĩa của từ** ở phần đầu vẫn chưa được giải quyết.
- Hướng khắc phục là **embedding theo ngữ cảnh** như ELMo và BERT, trong đó vector của từ thay đổi theo câu chứa nó.